中国科学院大学
University of Chinese Academy of Sciences

课程作业报告

基于 text-CNN 的电影评论情感分类

作者姓名：段宏键

学科专业：计算机系统结构

所在单位：中国科学院大学计算机科学与技术学院

2020 年 6 月

1. 摘要

本项目是为了实现对电影评论的情感分类。本项目设计并实现了一个 CNN 类型网络的架构（把 text-CNN 并行提取不同尺寸 gram 的特征变为串行化的提取特征，如同图片卷积一样，把输入的句子处理为正规的矩阵，然后当成单通道的图片来处理；其中有一个 embedding 层，然后是四层的卷积，ReLU，最大池化，最后跟三层的 ReLU 激活的全连接层），使用课程资源提供的预处理过的带有 label 的电影评论数据集，经过对数据集的重新划分（我认为原始数据集测试集所占的比例太小了），以及对中文文本内容的分析以及相应处理，然后经过 3 轮迭代在 2000 多条测试集的评论上达到了 84%左右的准确率、精确率、F1 值和召回率 。

1. 介绍

(1)

情感分类又称情感倾向性分析，是指对给定的文本，识别其中主观性文本的倾向是肯定还是否定的，或者说是正面还是负面的。

通常的网络内容会存在主观性文本和客观性文本。客观性文本不带有感情色彩和情感倾向，是对事物的客观性描述；主观性文本带有作者的喜好厌恶等情感倾向，是作者对各种事物的看法或想法。情感分类的对象是带有情感倾向的主观性文本。如果文本中包含客观内容与主观内容时，情感分类首先要进行文本的主客观分类。文本的主客观分类可以以情感词识别为主，利用不同的文本特征表示方法和分类器进行识别分类，对网络文本事先进行主客观分类，能够提高情感分类的速度和准确度。对于主观性文本，目前情感倾向性分析的研究工作主要思路分为**基于语义的情感词典方法**、**基于机器学习的方法**以及**基于深度学习的方法**。

文本情感分类与基于主题的文本分类相似但不同：基于主题的文本分类是把文本分类到各个预定义的主题上；情感分类是按照文本持有的情感、态度进行判断，并不是完全基

于内容本身。

基于机器学习的情感分类，其大致是:首先人工标注文本倾向性作为训练集，提取文本情感特征，通过机器学习的方法构造情感分类器，待分类的文本通过分类器进行倾向性分类。挖掘各种不同的特征能提高情感分类的能力。传统的特征提取方法有信息增益等。常用的分类方法有贝叶斯分类器、最大熵分类器等。使用有监督的机器学习的方法将电影评论分为正向和负向两类。文本情感分类的困难是复杂的情感表达和大量的情感歧义造成的。在基于机器学习的情感分类算法中，每篇文章被转换成一个对应的特征向量来表示。特征选择的好坏将直接影响情感分析任务的性能。

基于深度学习方法主要有两大类，一类是采用 CNN 网络结合传统语言学中的 N-Gram 模型（N 作为卷积核大小），另一种是基于循环神经网络 RNN 或 LSTM 等。深度学习方法把特征提取以及最后的分类均交给网络训练，这样能再机器学习方法的基础上进一步提高分类的准确率，但面临的问题是分类过程**“黑盒化”**，难以知道网络究竟是根据什么来进行分类的。

电影影评一般属于短评，本项目中我们要做的就是将任一条用户影评分类至 [positive,negative] 两个标签，这是个情感二分类问题。

(2)

首先，对于课程网站提供的原始数据集，我认为其对训练集、验证集、测试集的大小划分并不合理，**测试集只有 360 条左右的电影评论，并不足以说明训练模型的的情况**。所以我将所有数据集汇总后，随机把所有数据（26000 多条）中的十分之一作为测试集合。

其次，数据集是中文文本，需要进行处理成为数字之后才能进入进行网络训练。

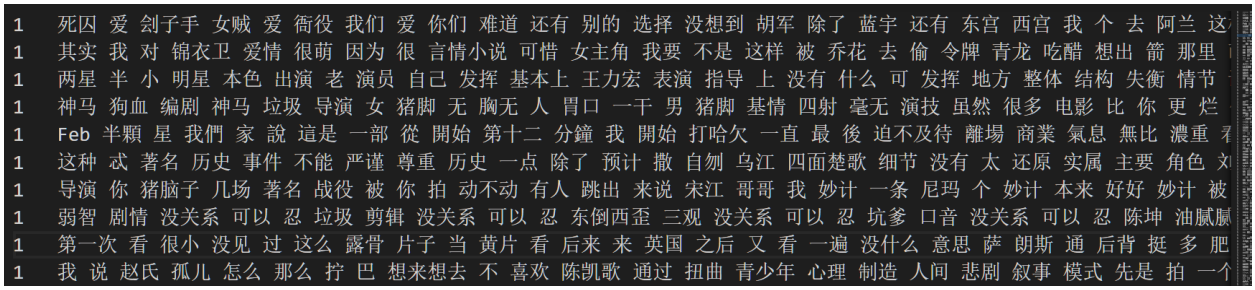

除此之外，观察数据集可知，每一个评论句子的长短是不一样的，我统计了一下数据集中所有句子的长度，发现最长的句子有 679 个词，所有句子平均却只有 50 个词，分布极度不平衡，如果采用 RNN 类的网络架构，只要保证同一个 batch 内部的句子数据长度一

致即可，而对于 CNN 类的网络架构，所有的句子长度都要相同才行。所以需要对句子长度做一个处理。

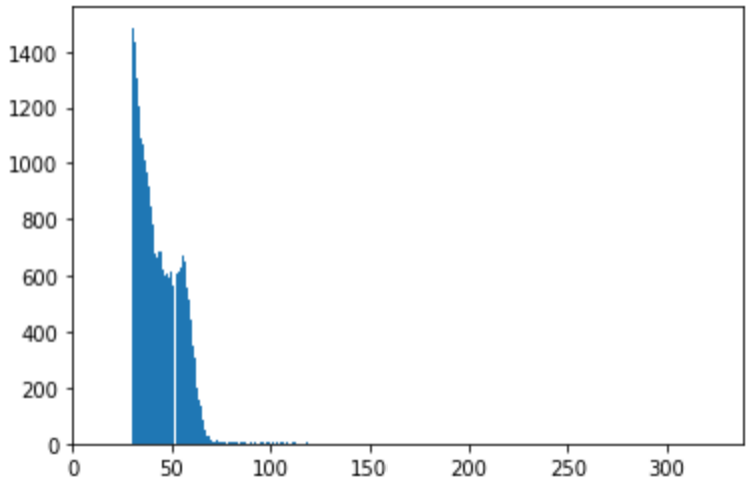

横轴：句子长度； 纵轴：对应长度的句子个数

(3)

为了解决上述问题，需要在训练之前对数据进行了大量的预处理。网络模型采用了 text-RNN 模型的变体，使用多个卷积层来模拟对不同层级 n-gram 的串行提取特征。同时每次卷积之后均使用 ReLU 和最大池化操作来减少特征维度，突出重要特征。最后使用三个全连接层来根据这些特征进行分类。

常规的 Text-CNN 模型如下：

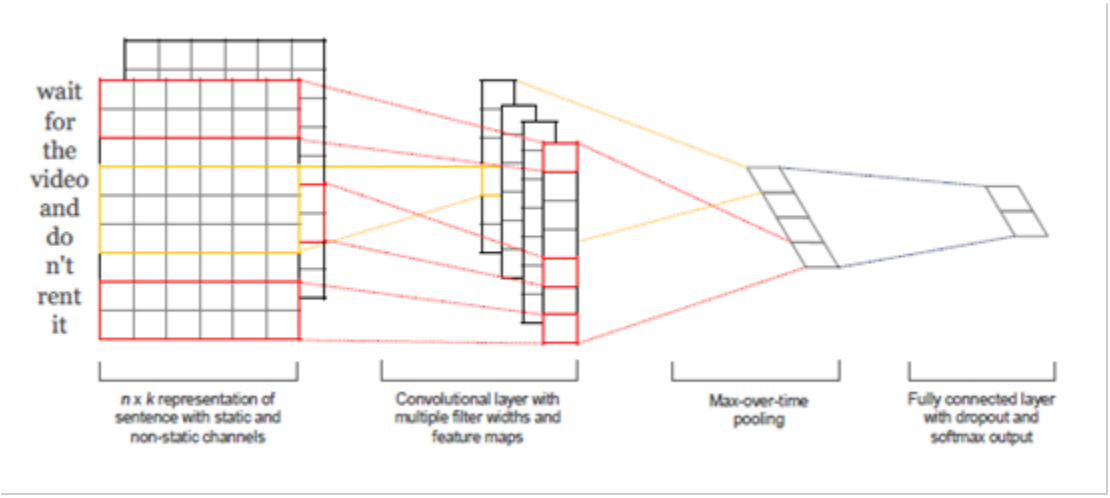

常规的 CNN 多层卷积的结构， 卷积核的宽度等于词向量的维度，经卷积后可以提取

文本的特征向量。与在图像领域应用类似，Text-CNN 可以设置多个卷积核以提取文本的多层特征，长度为 N 的卷积核可以提取文本中的 N-gram 特征。

我的模型是对 Text-CNN 的卷积操作做了一些修改。我并没有采用常规的 Text-CNN 的卷积操作。我把输入的 [句子的长度*词 embedding 的维度] 的向量当成一个单通道的图像，在这个图像上做多个多层的卷积，然后通过多层全连接网络把这个输入的“图像”类别输出。这样做的想法是希望追求更细粒度的词与词之间的关系，同时通过不同的卷积层抽取句子中不同层次的特征，以便更好地完成情感的识别与分类任务。

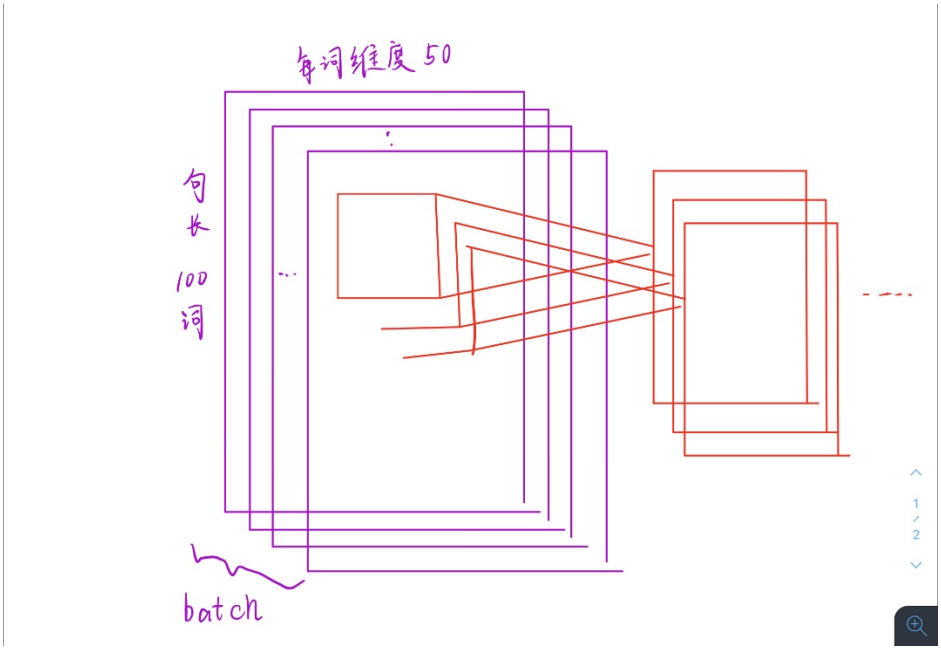

2. 解决方案

由于进行本实验时安装 torchtext 包，导致我本地的 pytorch 环境奔溃了，所以本实验全部在 google Colab 上完成。

整个实验过程遵循以下几个步骤：

数据准备阶段：

把所有的评论数据以及标签加载进来，对于标签不正常的数据直接放弃（只有几条标签不正常数据，所以放弃这些数据基本无影响）。对评论数据集中的中文词汇构建词汇与

数字 index 相互转化的词表{word：id}与{id：word}形式。然后根据预先训练好的word2vec构建训练语料中所含词语的word2vec，以便作预训练数据输入embedding层中。

根据上文“介绍”中第二小节对句子长度的分析，把每个句子的长度设置为 100，这个大概是平均句子长度的两倍，且大多数句子长度都小于等于 100，所以这样设置是合理的。不足长度的句子后续会被填充 0，大于长度的句子会被截取。

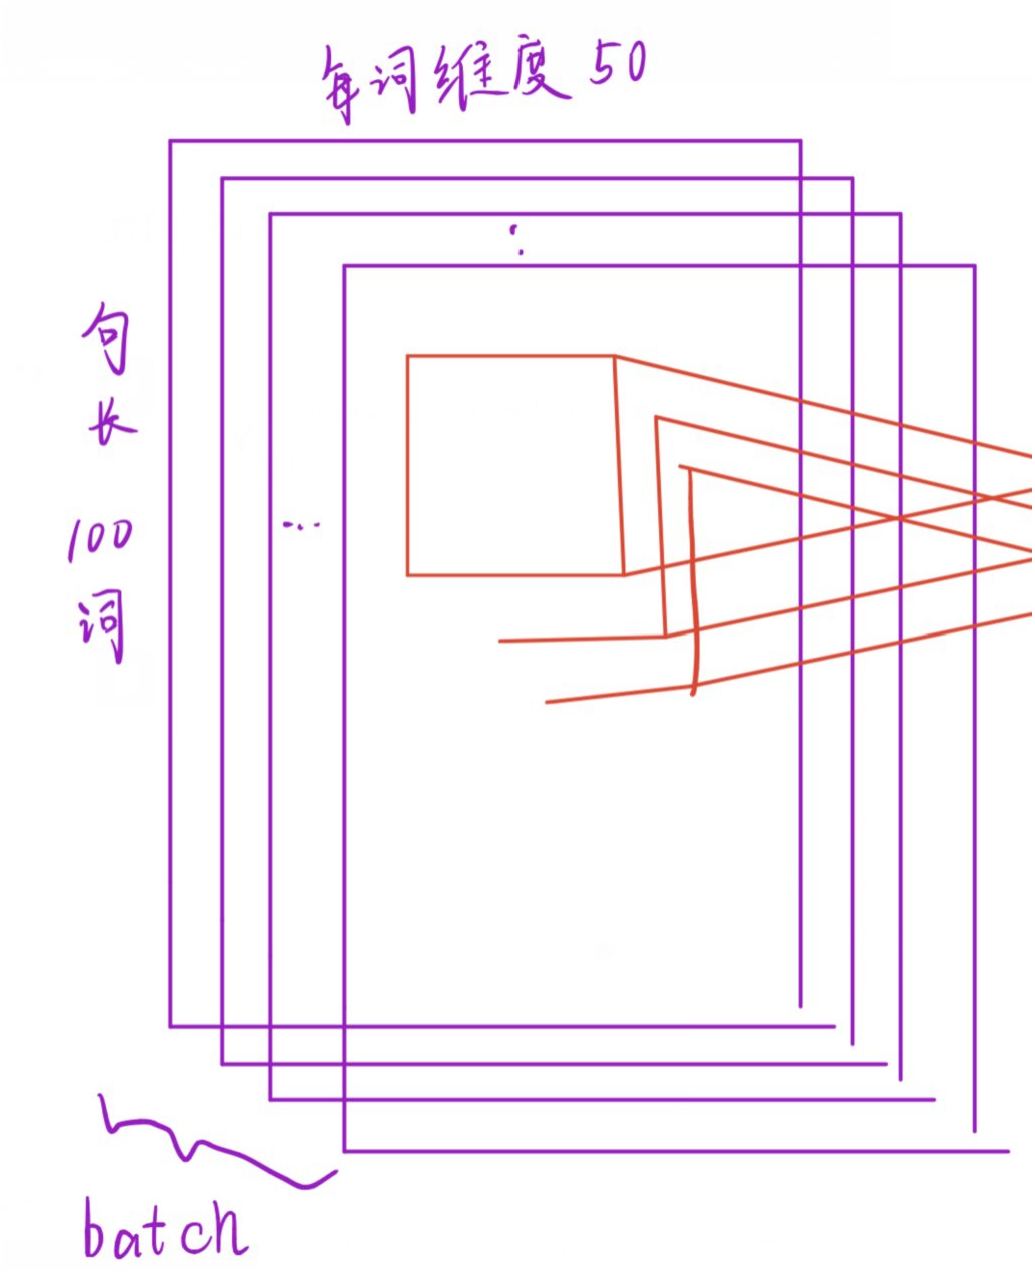

网络设计：

网络不是采用 text-CNN 结构，而是把每个句子的数据当成一个图片来进行卷积处理，

这样做的目的是希望能找到更细粒度的关系，同时采用多层卷积来提取高层次间的特征以及寻找特征间的关系。

网络结构如下所示：

```
textCNN(
  (embeding): Embedding(58463, 50)
  (conv1): Sequential(
    (0): Conv2d(1, 16, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
    (1): ReLU()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (conv2): Sequential(
    (0): Conv2d(16, 32, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
    (1): ReLU()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (conv3): Sequential(
    (0): Conv2d(32, 64, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
    (1): ReLU()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (conv4): Sequential(
    (0): Conv2d(64, 128, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
    (1): ReLU()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (fc1): Linear(in_features=2304, out_features=512, bias=True)
  (fc2): Linear(in_features=512, out_features=100, bias=True)
  (out): Linear(in_features=100, out_features=2, bias=True)
)
```

训练优化方法与损失函数如下：

```
EPOCH=3
LR = 0.001
optimizer = torch.optim.Adam(cnn.parameters(), lr=LR)
#损失函数
loss_function = nn.CrossEntropyLoss()
#训练批次大小
batch_size=100;
```

损失函数的设计采用交叉熵损失函数，优化方法是 Adam。

设置了学习率为 0.001，学习率采用固定模式。一共训练迭代了 3 轮（更多轮会过拟合）。

测试部分的设计与训练部分很相似，只是加载的数据集变为了测试数据集，同时去掉了误差反向传播的过程。

测试中除了自己累加计算准去率外，还使用 sklearn 工具来计算准确率、精确率、F1 值、召回率、混淆矩阵。

3. 实验结果和分析

实验配置如下：

深度学习平台：anaconda + pytorch（具体环境包依赖可以参见实验目录下的“环境依赖.txt”）

数据集：课程资源提供的电影评论数据并按照训练集与测试及 9：1 重新划分。

训练环境：google colaboratory(训练使用的 runtime 是 GPU 类型)

测试环境：google colaboratory，自己的笔记本电脑环境崩掉了

训练过程中会定时输出 loss 值，每轮训练均之后均会进行验证，以防止过拟合的情况出现。

网络模型训练过程中的 loss 变化如下：

```
TRAIN:EPOCH [3/3],batch[100/233],train loss is: 0.11233361065387726, now accuracy is: 0.97
TRAIN:EPOCH [3/3],batch[110/233],train loss is: 0.22163204848766327, now accuracy is: 0.89
TRAIN:EPOCH [3/3],batch[120/233],train loss is: 0.17236606776714325, now accuracy is: 0.93
TRAIN:EPOCH [3/3],batch[130/233],train loss is: 0.17959044873714447, now accuracy is: 0.92
TRAIN:EPOCH [3/3],batch[140/233],train loss is: 0.27104651927948, now accuracy is: 0.93
TRAIN:EPOCH [3/3],batch[150/233],train loss is: 0.1784396767616272, now accuracy is: 0.92
TRAIN:EPOCH [3/3],batch[160/233],train loss is: 0.1748771071434021, now accuracy is: 0.96
TRAIN:EPOCH [3/3],batch[170/233],train loss is: 0.3362520635128021, now accuracy is: 0.89
TRAIN:EPOCH [3/3],batch[180/233],train loss is: 0.10871785879135132, now accuracy is: 0.98
TRAIN:EPOCH [3/3],batch[190/233],train loss is: 0.277923047542572, now accuracy is: 0.89
TRAIN:EPOCH [3/3],batch[200/233],train loss is: 0.18454867601394653, now accuracy is: 0.95
TRAIN:EPOCH [3/3],batch[210/233],train loss is: 0.2693216800689697, now accuracy is: 0.92
TRAIN:EPOCH [3/3],batch[220/233],train loss is: 0.22866123914718628, now accuracy is: 0.92
TRAIN:EPOCH [3/3],batch[230/233],train loss is: 0.10473629087209702, now accuracy is: 0.98
```

可以看到第三轮训练的时候，对一个 batch 为 100 的句子的准确率就比较高了，经验证更多轮次的训练会导致过拟合而是得测试误差增大。

三轮训练之后的测试结果（包括准确率、精确率、F1 值、召回率、混淆矩阵）如下：

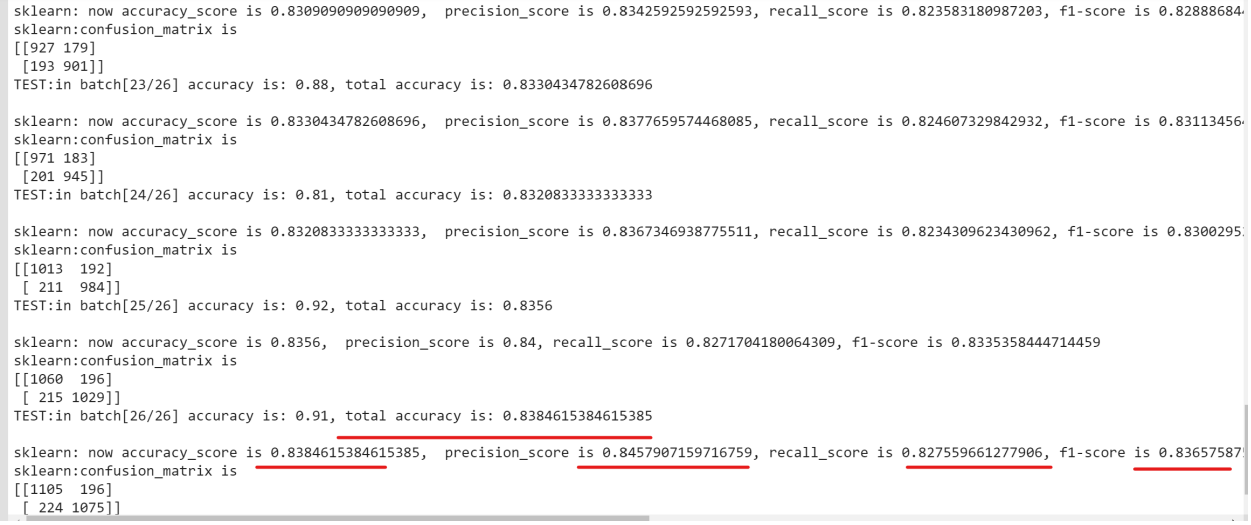

Accuracy 是当前 batch（100 个句子）中的准确率，total accuracy 是自己计算的总的准确率，接下来是 sklearn 工具计算的准确率、精确率、召回率、F1 值与混淆矩阵，在 2600 多个测试句子上，总的准确率能达到近 84%。

4. 结论

这个实验我探究了把文本句子处理为标准矩阵之后，使用 CNN 中处理图像类似的方法来处理句子的 embedding 矩阵，发现这种处理方法在很少的训练轮次下就能有比较好的识别率，但是这种把句子当成图像处理的网络的上限在哪里并不知道。相对于 RNN 类型网络的结构，CNN 类型的网络可能在网络设计的含以上没有 RNN 类型的网络自然，但 CNN 类型的网络由于可以并行化的计算，所以训练时间会非常短，而且在较少的轮次就能取得相对还行的效果。同时，本实验对句子的处理以及网络设计也说明了，除了图像数据会形成各个层次的特征，可以用卷积提取外，文本数据经过 embedding 成为类似图像的矩阵数据之后，也会有各个层次的特征，可以使用 CNN 网络结构中的卷积操作进行提取。

更进一步的想法是把文本句子处理为正规的矩阵数据，这个矩阵数据可以是多层的，其中每一层的词 embedding 来自于不同预训练样本的 word2vec 数据，同时加入对矩阵的类似图像的处理（旋转、翻译、裁剪等等），然后采用 CNN 网络架构训练和测试。

5. 参考文献

[1] 课程资源《实验四 电影评论情感分类实验指导书》

[2] Kim Y .2014--《Convolutional Neural Networks for Sentence Classification》